Kaggle/petfinder

Group: Team A | 2. mérföldkő: adat-előkészítés és jellemzőelemzés

1. Feladat és adatbázis

A feladat az **AdoptionSpeed** (0–4) előrejelzése, vagyis egy **ötosztályos, sorrenddel rendelkező osztályozási probléma**. Egy rekord egy PetFinder-hirdetés, amely egy vagy több állatot is leírhat. Az adatok numerikus, kategorikus, szöveges és képi információt tartalmaznak.

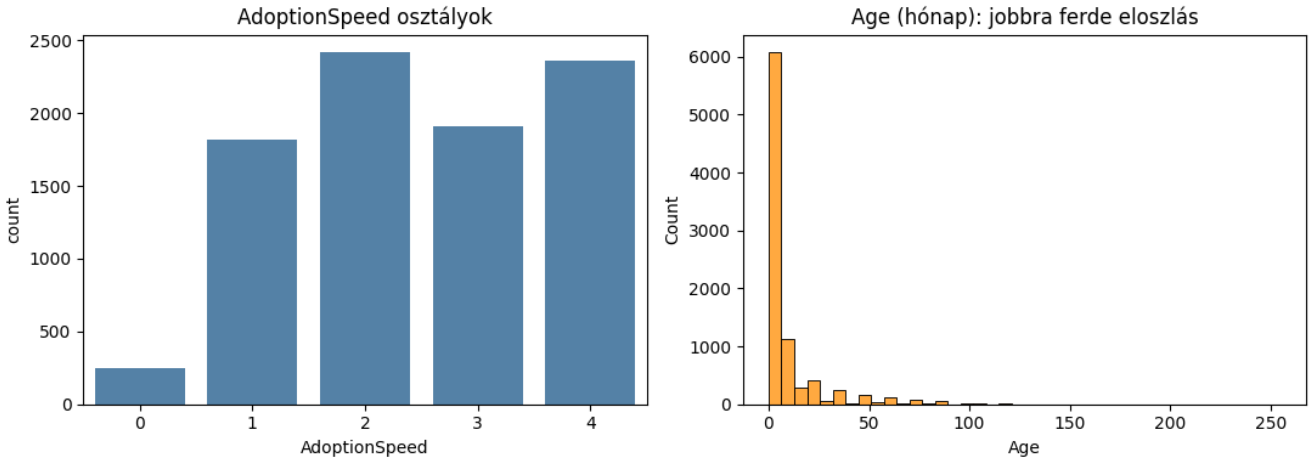
Adathalmaz	Méret	Szerep
Hivatalos Kaggle train	**14 993 × 24**	Címkézett fejlesztési adatok
Hivatalos Kaggle test	**3 972 × 23**	Címkézetlen; csak predikció

2. Adatfelosztás és értékelési stratégia

A **rétegzett, csoportos felosztás** során egy megmentő (RescuerID) valamennyi hirdetése ugyanabba a részhalmazba kerül. Ennek oka, hogy ugyanazon megmentő hirdetései hasonlóak lehetnek. Közben az öt örökbefogadási kategória arányát is igyekeztünk megőrizni. Ellenőriztük, hogy egy megmentő sem szerepel két részben.

Belső részhalmaz	Darab	Arány	Felhasználás
Train	**8 751**	58,4%	Transzformációk és modellek illesztése
Validation	**3 053**	20,4%	Három jellemzőkészlet összevetése
Belső test	**3 189**	21,3%	Egyszeri, végső ellenőrzés

3. Előzetes adatelemzés (csak a trainen)



1. ábra. Az AdoptionSpeed=0 ritka (2,8%), vagyis az öt kategória gyakorisága jelentősen eltér. Az életkor jobbra ferde eloszlása a logaritmikus átalakítást indokolja.

4. Adatminőség javítása

A hiányzó és ellentmondásos értékeket először megszámoltuk, majd egységes tisztítási szabályokkal rendeztük mindkét adathalmazban. **Egyetlen hirdetés sem lett törölve**, és a célváltozót sem módosítottuk.

Probléma (címkézett adatok)	Előtte	Utána	Javítás és indok
Hiányzó valódi név	1 265	1 416	151 névhelyettesítő átállítása hiányzóra
Névhelyettesítő (pl. No Name)	151	0	Egységes NA; nem valódi nevek
Hiányzó Description	13	0	Üres szöveg a biztonságos TF–IDF-hez
Breed1=0 és Breed2>0	5	0	Ismert másodlagos fajta előre hozása
Breed1=Breed2>0	1 510	0	Második kód törlése: nem két külön fajta
Color2=0 és Color3>0	0	0	Kódok előre rendezése, ha szükséges

Megőrzött információ: az egészségügyi mezőkben az „igen”, „nem” és „nem biztos” külön kategóriák maradtak. Ellenőriztük, hogy az életkor és a díj nem negatív, az állatok száma pozitív, a fényképek száma egész érték. A szokatlan, de lehetséges értékeket megtartottuk.

5. Új jellemzők és numerikus transzformációk

Az eredeti adatokból **10 új, értelmezhető jellemzőt** képeztünk. Ezek mind egy-egy hirdetés ismert értékeiből számolhatók, és segíthetnek feltárni az eredeti oszlopokban kevésbé látható összefüggéseket.

Jellemző	Hogyan készül?	Miért hasznos?
Age_Log	log(1 + Age)	Ferde életkoreloszlás összenyomása
Fee_Log	log(1 + Fee)	Extrém díjak hatásának mérséklése
Is_Free	Fee == 0	Ingyenesség elkülönítése
Is_Group	Quantity > 1	Több állatot tartalmazó hirdetések
Fee_Per_Pet	Fee / Quantity	Egy állatra eső díj
Has_Name	Name nem hiányzó	Hirdetés információteljessége
Is_Mixed	Breed2 > 0 vagy Breed1=307	Keverékfajta-jelzés
Medical_Yes	3 orvosi mezőből az 1-esek száma	Pozitív gondozási státuszok
Medical_Unknown	3 orvosi mezőből a 3-asok száma	Bizonytalan egészségi adatok
Desc_Words	Leírás szavainak száma	Szöveg hosszának jelzése

A nyers életkor és díj mellett a logaritmikus alakjukat is megtartottuk. A köztük lévő hasonlóságot a korrelációs elemzés segít megérteni.

A további feldolgozás kulcsfogalmai

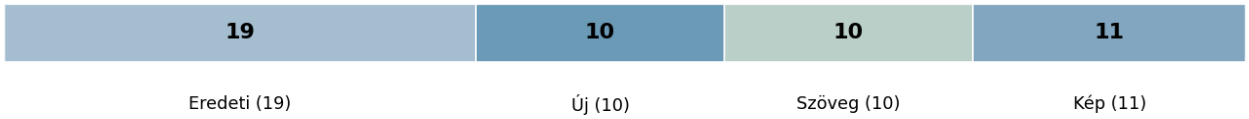
Fogalom	Mit jelent, és miért alkalmazzuk?
TF–IDF	A szöveg szavait számokká alakító súlyozás: nagyobb súlyt kap a hirdetésben jellemző, de a teljes szöveggyűjteményben ritkább szó. Így a gyakori töltelékszavak kevésbé dominálnak.
TruncatedSVD	Lineáris dimenziócsökkentés: a sok szöveges/képi értéket 10 új összefoglaló tengelyre vetíti. Csökkenti a méretet, de információt veszít.
ResNet50	ImageNet-képeken előtanított mély neurális háló; a végső osztályozó nélkül egy fotóból 2 048 általános képi jellemzőt nyerünk ki. Itt a hálózat súlyait nem tanítjuk tovább.

6. Szöveges és képi jellemzők előállítása

Modalitás	Mit és hogyan?	Eredmény / miért?
Szöveg	Az állat leírásából TF–IDF-súlyozással számszerű szójellemzőket, majd SVD-vel tömör összefoglalást készítünk.	10 szöveges dimenzió; a tömörítés 10,6% varianciát őriz meg
Kép	Az első fényképet egy előre tanított ResNet50 elemzi; az így nyert 2 048 képi jellemzőt SVD-vel tömörítjük.	10 képi dimenzió; 36,1% variancia; 14 652/14 993 (97,7%) feldolgozható kép
Hiányjelző	Külön megkülönböztetjük a képpel rendelkező és a képhiányos hirdetéseket.	A kép hiánya sem keveredik a tényleges képi értékekkel

A módszer indoklása: a szöveg és a fotó olyan információt hordozhat, amely a táblázatban nem szerepel. A szöveg- és képtömörítést a tanítóadatokon alakítottuk ki, majd ugyanúgy alkalmaztuk a többi adatra. A képi hálózatot nem tanítottuk újra, és hirdetésenként csak az első fotót használtuk: ez gyorsabb, de nem őrzi meg az összes képi információt.

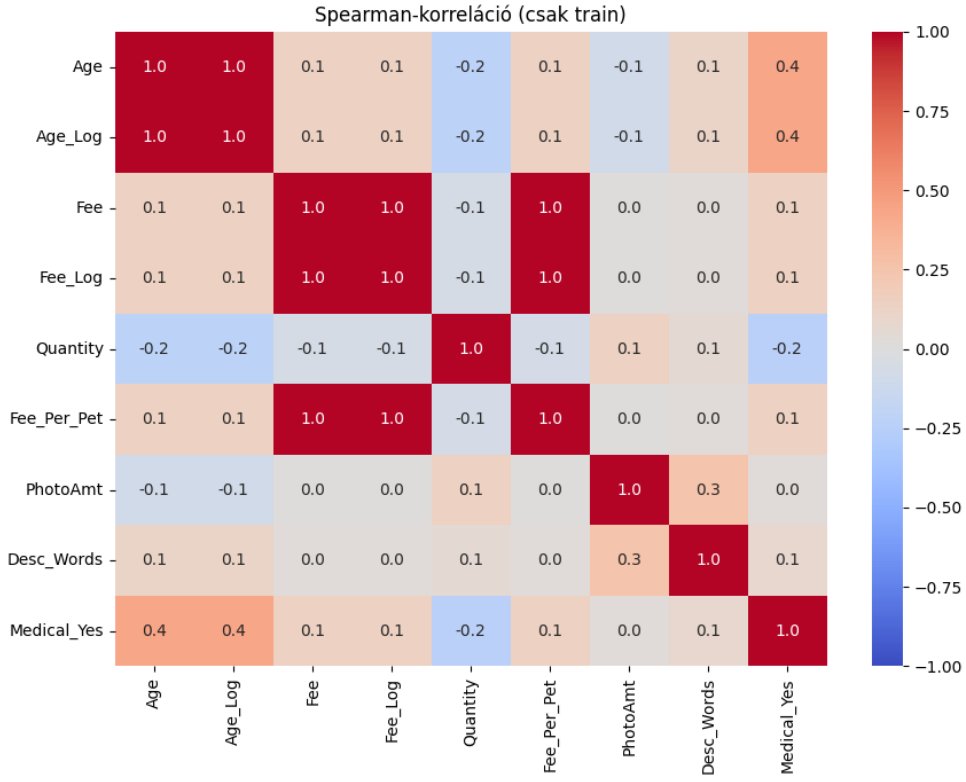
Az 50 jellemző összetétele



A modell 19 eredeti és 10 új táblázatos, 10 szöveges, továbbá 11 képi és képhiányt jelző változót használ. Az azonosítókat és a megjósolandó célváltozót nem tekintjük előrejelző jellemzőnek. A számmal kódolt kategóriákat nem folytonos mennyiségekként kezeljük.

7. Jellemzőkapcsolatok: Spearman-korreláció

Spearman-korreláció: két jellemzőnél külön-külön sorba rendezi a hirdetéseket, majd összeveti a sorrendeket. Például az életkor és logaritmusa ugyanazt a sorrendet adja, ezért kapcsolatuk +1. Azonos sorrendnél +1, fordítottnál -1 az érték; 0 körül nincs következetes növekvő vagy csökkenő kapcsolat. Így keressük a hasonló információt hordozó jellemzőket: az értékek közti különbségek helyett a sorrendjüket vizsgáljuk.



2. ábra. Az életkor és logaritmusa azonos sorrendet ad (ρ≈1), noha az értékek közötti különbségek már nem ugyanakkorák. A fotók száma és a leírás hossza között gyengébb pozitív kapcsolat látható (ρ≈0,3). A korreláció nem bizonyít ok-okozati összefüggést.

8. Jellemzőkiválasztás és validáció

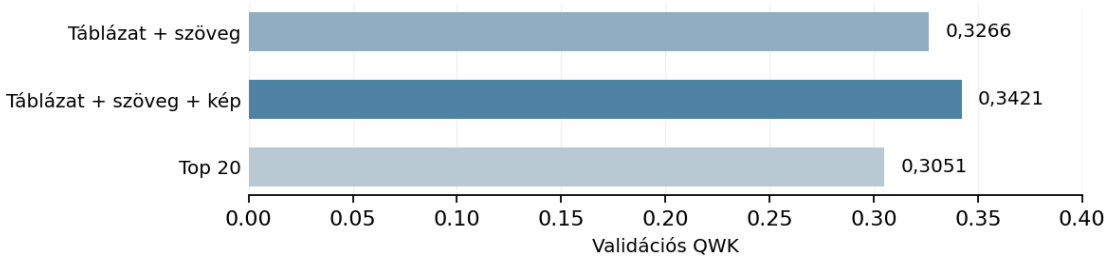
A **LightGBM** egy olyan gépi tanulási modell, amely **sok egyszerű döntési fát kapcsol össze**. Egy fa például az életkor vagy a fajta alapján hoz egymást követő döntéseket. A következő fák ott próbálnak javítani, ahol az előzőek hibáztak; ezért a végső előrejelzés több fa együttes tudására épül. Különösen alkalmas vegyes, számszerű és kategorikus jellemzőkhöz, valamint nemlineáris kapcsolatokhoz.

A **gain fontosság** megmutatja, hogy egy jellemző mennyit segített a fák döntéseinek javításában a tanítás során. Ebből rangsoroltuk a változókat, és kipróbáltuk a 20 legfontosabbat külön is. A nagy fontosság nem jelent bizonyított ok-okozati hatást.

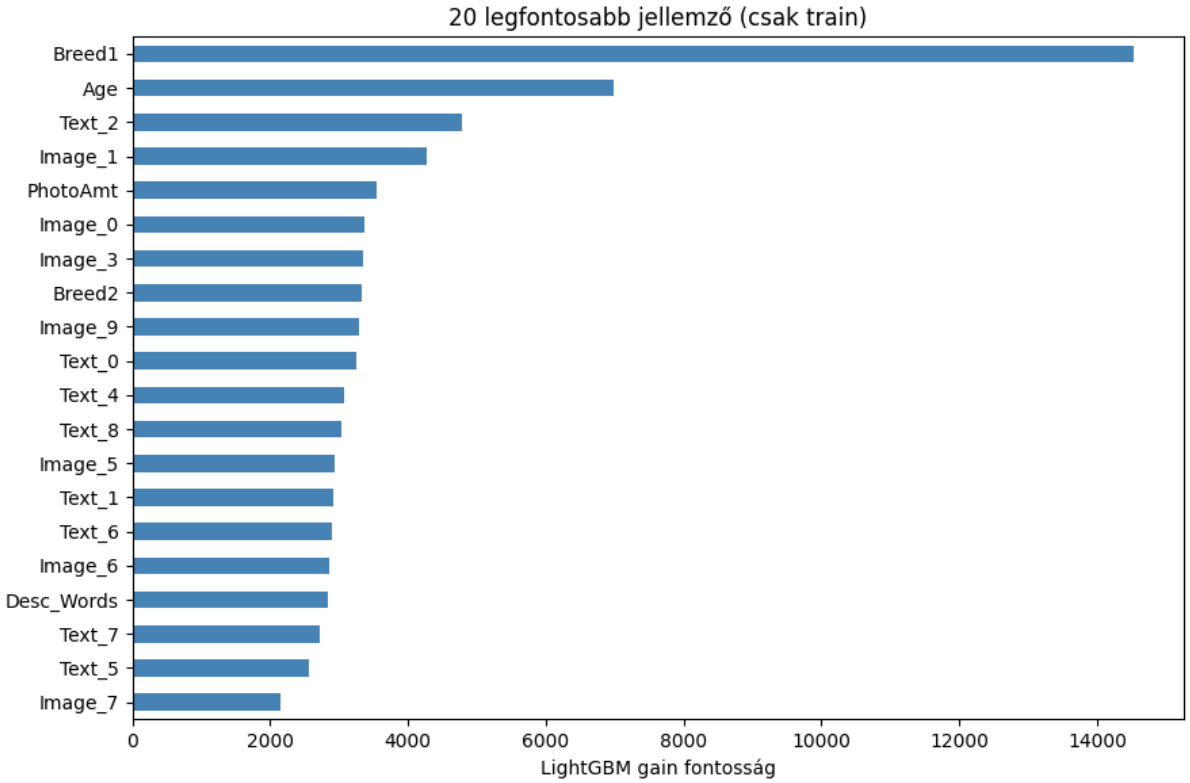
Validációs változat	Jellemző	QWK ↑	Macro-F1 ↑	Accuracy ↑
Táblázat + szöveg	39	0,3266	**0,3108**	**0,3767**
Táblázat + szöveg + kép	**50**	**0,3421**	0,3021	0,3682
Top 20 (gain)	20	0,3051	0,2865	0,3492

QWK (Quadratic Weighted Kappa): a jósolt és a valódi 0-4 kategóriák egyezését értékeli. A nagyobb tévedést jobban bünteti: 0 helyett 4-et jósolni 16-szor akkora hibasúlyt kap, mint 0 helyett 1-et. A hibát ahhoz is viszonyítja, ami azonos kategóriaarányú, véletlen jóslatoknál várható. Az 1 tökéletes, a 0 véletlen szintű, a negatív érték annál rosszabb egyezés. Azért ezt használjuk a modellválasztáshoz, mert itt a kategóriák sorrendje és a tévedés nagysága is számít.

Modellválasztás: a három változat közül a legnagyobb validációs QWK-t elérő, **50 jellemzős** modell nyert. A képek hozzáadása a QWK-t **0,3266-ról 0,3421-re** javította, de a többi közölt mérőszám kissé romlott. A csupán 20 jellemzős modell szintén gyengébb volt: nem minden információt érdemes elhagyni a kisebb jellemzőszám kedvéért.



3. ábra. Három jellemzőkészlet validációs QWK-értéke; a képet használó 50 dimenziós változatot választottuk.

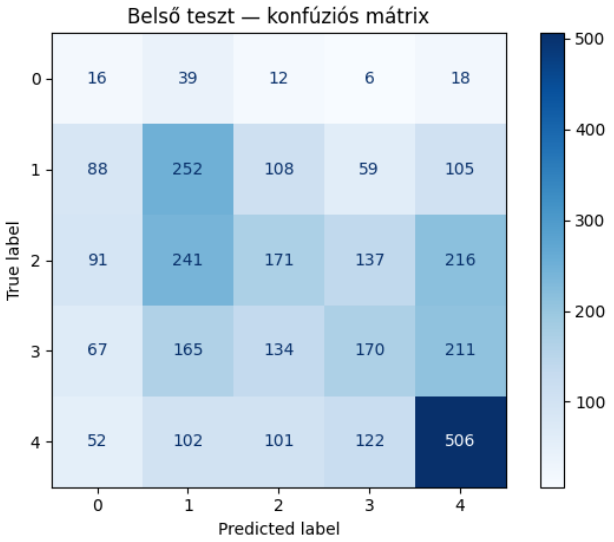


4. ábra. A fajta (Breed1), az életkor (Age) és több szöveges/képi komponens magas gain-értéke azt jelzi, hogy mindhárom modalitás használható információt hordoz. A rangsor mintafüggő; nem bizonyítja, hogy a változók okozzák az örökbefogadási sebességet.

9. Egyszeri belső tesztértékelés

A validáció alapján kiválasztott **50 jellemzős** modellhez a félretett 3 189 hirdetés eredményeinek megtekintése után már nem változtattunk a módszeren. Így reálisabban becsülhető, hogyan teljesít új megmentők hirdetésein.

Teszt QWK	Macro-F1	Accuracy	0. osztály F1	4. osztály F1
0,3217	**0,2959**	**0,3496**	0,08	0,52



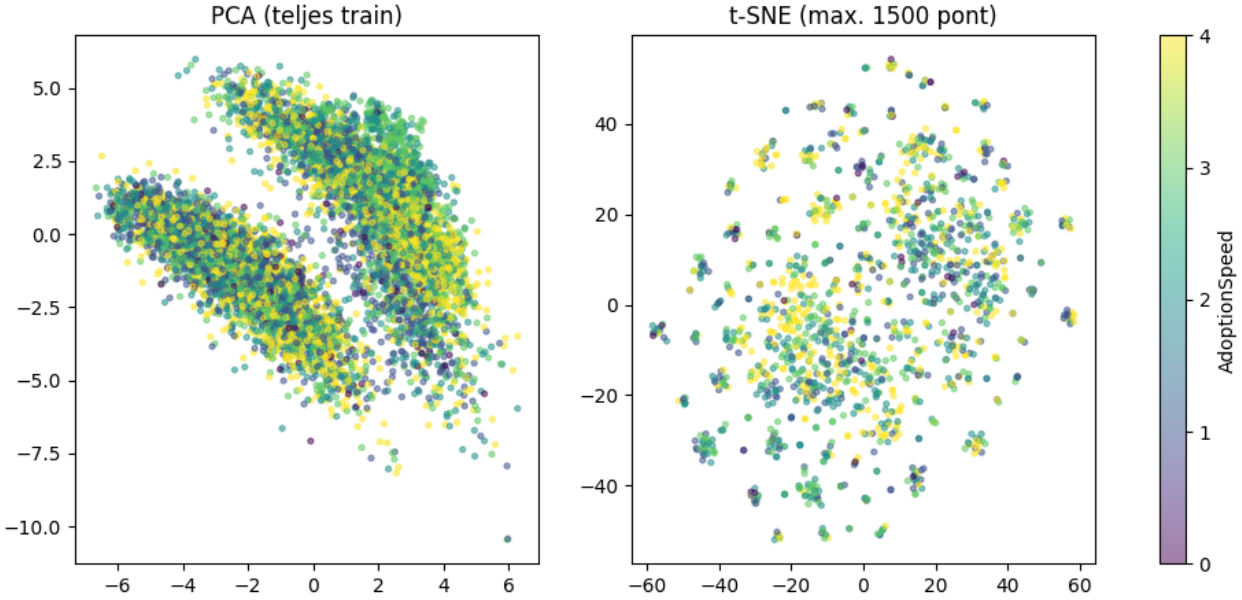
Konfúziós mátrix

5. ábra. A sorok a valódi, az oszlopok a jósolt címkék. A ritka 0-s kategória 91 esetéből mindössze **16-ot** talált el a modell; a 4-es kategóriában 883-ból **506** volt helyes.

A mátrixból az is látszik, mely osztályokat téveszti össze gyakran: például a valódi 2-es kategóriából 241-et 1-esnek, 216-ot 4-esnek jósolt. Az összesített pontosság ~35%, ezért a modell további fejlesztést igényel.

10. A jellemzőtér vizsgálata és következtetések

A **PCA és a t-SNE** az 50 jellemzővel leírt hirdetéseket síkbeli ponttérképpé alakítja: egy pont egy hirdetés, színe az örökbefogadási kategória. Így láthatóvá válnak a csoportok és a kategóriák átfedései. A **PCA** olyan, mint a pontfelhőről a legjobb irányból készített fénykép: az 50 jellemző súlyozott összegeiből két új tengelyt képez, hogy a hirdetések közötti eltérésekből minél több látszódjon. A **t-SNE** inkább szomszédsági térkép: megkeresi, mely hirdetések hasonlítanak az eredeti jellemzőik alapján, majd úgy rendezi a pontokat, hogy a hasonlók közel maradjanak. A PCA a fő eltéréseket, a t-SNE a helyi csoportokat segít áttekinteni. Egyik sem a címkék alapján rendez; a t-SNE tengelyeinek nincs külön jelentésük, a távoli csoportok távolsága nem mérvadó. A vetítés információvesztéssel jár.



6. ábra. A teljes trainen számított 2D PCA mindössze **3,7%** varianciát magyaráz; a t-SNE 1 500 véletlen train mintát vizsgál. A színek átfednek, de a 2D vetítésből nem következik, hogy a teljes jellemzőtérben nincs elkülönülés.

Korlátok és megismételhetőség. A felosztást, a választott jellemzőket és az eredményeket rögzítettük. Egyetlen felosztásból azonban nem ítélhető meg a teljesítmény stabilitása; a képek közül csak az elsőt használtuk, és a tömörítés információt veszít. A belső teszt **nem** a Kaggle rejtett tesztje. A modellválasztás lezárása után mind a 14 993 címkézett hirdetést felhasználtuk a végső előrejelző modell tanításához.